

Objetivo

Comparar dos estrategias de recuperación sobre un corpus mínimo de diez documentos (d01–d10) y seis consultas (q1–q6), cada una con un único documento relevante (q1→d04, q2→d03, q3→d08, q4→d05, q5→d09, q6→d02): (1) una línea base léxica con TF-IDF y similitud coseno, y (2) semántica latente (LSA) proyectando la misma matriz TF-IDF a 4 dimensiones. Se evalúan Hit@1, Hit@3 y MRR, se analizan los fallos por consulta y se discute qué aportaría un recuperador denso, en particular para q5.

Método

- **Parte 1 (TF-IDF):** vectorización de los diez documentos con `TfidfVectorizer` de scikit-learn (parámetros por defecto); para cada consulta se calcula la similitud coseno contra los diez documentos y se ordenan. Métricas sobre las seis consultas: Hit@1 (relevante en la posición 1), Hit@3 (relevante dentro del top 3) y MRR (promedio del recíproco del rango del relevante).
- **Parte 2 (LSA):** sobre la misma matriz TF-IDF, proyección a 4 dimensiones con `TruncatedSVD(n_components=4, random_state=0)`; ranking por coseno en el espacio latente y recálculo de las tres métricas. Ambos métodos se reportan en una sola tabla comparativa.
- **Parte 3:** con los rankings de ambos métodos, identificación de las consultas cuyo relevante queda fuera del top 3 y análisis de los términos compartidos entre cada consulta, su relevante y los documentos no relevantes mejor posicionados.

Resultados

Declaración de resultados no disponibles. La ejecución que debía producir las cifras no se completó:

- La subtarea **T1 (Parte 1)** no tiene resultado (fallida): **no se reportan sus cifras** (Hit@1, Hit@3 y MRR de TF-IDF).
- La subtarea **T2 (Parte 2)** no tiene resultado (omitida): **no se reportan sus cifras** (métricas de LSA ni tabla comparativa).
- La subtarea **T3 (Parte 3)** no tiene resultado (omitida): no se disponen de los rankings, por lo que **no puede listarse en qué consultas falla cada método** ni los términos compartidos calculados.

La tabla comparativa exigida queda por tanto vacía; cualquier cifra en ella sería inventada y se omite:

Métrica	TF-IDF	LSA (4 dim.)
Hit@1	—	—
Hit@3	—	—
MRR	—	—

(celdas sin dato: mediciones no disponibles; pendiente re-ejecución del pipeline).

Discusión

Análisis por consulta (sin soporte medido). Al no existir el resultado de T3, no puede afirmarse con evidencia de ejecución en qué consultas falla cada método. Sí puede razonarse cualitativamente a partir del texto del corpus: q5 («¿Qué hace que el modelo sea más determinista al elegir la siguiente palabra?») es la única consulta cuyo relevante (d09: «La temperatura reescala los logits antes del softmax; valores bajos concentran la probabilidad») no comparte ningún término de contenido con la consulta («determinista» vs. «concentran la probabilidad»; «palabra» vs. «logits/softmax»). TF-IDF, que depende del solapamiento léxico exacto, es candidata a fallar ahí; LSA a 4 dimensiones podría mitigarlo vía co-ocurrencia, pero con solo diez documentos el espacio latente es grueso y puede mezclar temas, degradando consultas que sí dependen de términos precisos (q1–q4 y q6 comparten literalmente «función de ranking léxica», «frecuencia de términos», «fragmentos... prompt», «matrices de bajo rango», «orientación... vectores» y «autoatención... feed-forward» con sus relevantes). Estas hipótesis quedan sin confirmar mientras no se re-ejecuten T1–T3.

Recuperador denso para q5 y sus costos. Un recuperador denso con embeddings de un modelo entrenado resolvería mejor q5 porque aprende, en grandes corpus, a alinear paráfrasis y relaciones semánticas: «más determinista» quedaría cerca de «valores bajos concentran la probabilidad» aunque no compartan vocabulario, resolviendo justo el desajuste léxico que penaliza a TF-IDF y que LSA, entrenada implícitamente sobre diez documentos, apenas puede captar. Frente a TF-IDF, sus costos son: (i) entrenamiento o uso de un modelo preentrenado, con datos y cómputo asociados; (ii) inferencia neuronal (paso de red) por documento y por

consulta, con mayor latencia y posible necesidad de GPU; (iii) almacenamiento e indexación de vectores densos; (iv) mantenimiento: versionado del modelo, re-cálculo de embeddings ante actualizaciones y sensibilidad a cambio de dominio; y (v) menor interpretabilidad que los pesos léxicos. TF-IDF sigue siendo gratuito de entrenar, rápido e interpretable, y suficiente cuando la consulta y el documento comparten términos, como ocurre en q1–q4 y q6.

