



UNIVERSIDAD SAN FRANCISCO DE QUITO

Maestría en Inteligencia Artificial

IA Generativa y Agentes

Taller 3 v2—Un solver multiagente con GraphRAG: del enunciado en PDF al reporte medido.

Jessica Ballesteros, Miguel Álvarez, Darlyn Ludeña

6 de octubre de 2026

Repositorio: github.com/akroasis0301/taller-03-opcional-alvarez-ballesteros-lude-a

Ruta, modelo y fecha. H200 de la USFQ por VPN (GlobalProtect). LLM: vLLM en 172.28.230.10:12555, id zai-org/GLM-5.3-Flash, leído de /v1/models (no escrito a mano). Embeddings: bge-m3:latest en el Ollama del mismo servidor (puerto 11434). Juez de la Parte 4: gemma3:27b en ese Ollama. Corridas finales, todas el **5 de octubre de 2026** (hora de Ecuador, UTC-5): completo r1 y r2 de 17:59 a 18:50; sin_grafo r1 y r2 de 18:50 a 19:53; tareas reales S1 y S2 de 19:58 a 21:05; el juez de 21:12 a 21:32. Las Partes 1 y 2 corrieron con un solo modelo. Costo: 0 USD (sin clave de API).

1. Parte 0 — Tres fallas que no fallan

La Parte 0 reproduce, antes de construir nada, tres cosas que un solver ingenuo hace mal sin dar ningún error: un LLM que “resuelve” una tarea sin ejecutarla, un RAG plano que pierde la referencia entre partes y un evaluador que confunde un `returncode == 0` con un experimento. Cada una justifica una de las correcciones de la Parte 1.

- **0.a — El solver que no ejecuta.** Entregable: salida, la ruta y el id del modelo, y tres frases: por qué que las cifras estén cerca no las hace aceptables, qué cifra del reporte habría cambiado una conclusión, y qué tendría que comprobar un verificador para detectar esto sin conocer las respuestas correctas.

Se ejecutó `python parte0/a_llm_sin_ejecutar.py` con la H200 (vLLM 12555, zai-org/GLM-5.3-Flash) el 2026-10-03: 12 028 tokens de salida en 61,72 s. La salida fue:

```
Medido ejecutando el código (sklearn, semilla 42):
```

```
NB accuracy    0.9474
NB F1 macro    0.9429
LR accuracy    0.9883
LR F1 macro    0.9875
```

```
LLM sin herramientas: zai-org/GLM-5.3-Flash, 2026-10-03, 12028 tokens de salida, 61.72 s, fin=stop
```

```
reporte en parte0/reporte_sin_ejecutar.md; 24 cifras con decimales:
0.30, 0.9415, 0.9370, 0.9825, 0.9812, 0.9123, 0.9298, 0.9357, 0.9415, 0.9415, 0.9064, 0.9415, 0.9649,
0.9766, 0.9825, 0.94, 0.9123, 0.9064, 0.9825, 0.9415 ...

Procedencia: 0 de 24 cifras salen de una ejecución (no hubo ninguna). Compáralas con las medidas
arriba.
¿Dice el reporte que las cifras son estimadas? no
```

Ilustración 1. Salida de a_llm_sin_ejecutar.py: las cifras medidas frente a las del reporte sin ejecutar (Parte 0.a)

Por qué que las cifras estén cerca no las hace aceptables. El reporte dice 0,9415 para Naive Bayes (medida: 0,9474) y 0,9825 para la regresión logística (medida: 0,9883): están cerca, pero ninguna salió de una ejecución (0 de 24 cifras con respaldo). “Cerca” solo se sabe porque esta vez alguien ejecutó el experimento al lado; sin esa ejecución no hay forma de distinguir una cifra plausible de una correcta, y el reporte no declara que sean estimaciones.

Qué cifra habría cambiado una conclusión. La de la curva con pocos datos: con el 5 % del entrenamiento el reporte da Naive Bayes 0,9123 contra regresión logística 0,9064, y de ahí concluye que con pocos ejemplos conviene el generativo (el cruce de Ng y Jordan). La diferencia es un acierto sobre 171: con un acierto más para la regresión logística la conclusión se invierte, y ninguna de las dos cifras tiene una ejecución detrás (medido con el pipeline estandarizado: 0,9415 y 0,9298). En la corrida del enunciado (2026-10-02) el modelo llegó a inventar 0,7251 para la regresión logística: un cruce exagerado que confirmaba la tesis.

Qué tendría que comprobar un verificador sin conocer las respuestas. Que cada cifra del reporte aparezca en algo que escribió una ejecución (un resultados.json de un script que terminó bien) o en el enunciado, y devolver por su nombre las que no. Es la comprobación de procedencia (corrección C5).

Conclusión: una cifra sin procedencia no es un resultado aunque acierte. El modelo produjo 24 cifras con aspecto de medidas y ninguna salió de una ejecución; la única defensa que no necesita conocer la respuesta es exigir que cada cifra tenga un origen.

- **0.b — El RAG plano que pierde la referencia.** Entregable: la salida y tres frases: por qué esta falla es de la recuperación y no de la generación, qué haría un LLM con el primer contexto, y por qué la arista se extrae con una regla y no se le pide al LLM.

Pregunta del programador: “¿Con qué datos y con qué partición se calcula la curva de aprendizaje?”

```
1) RAG plano: los 2 fragmentos más similares (TF-IDF, coseno)
Parte 4      sim=0.293
Parte 3      sim=0.243
El contexto cubre: X conjunto de datos  X proporción de prueba  X prueba intocable
```

```
2) Los mismos 2 fragmentos, más un salto por las aristas depende_de del grafo
Parte 4 -depende_de→ (ninguna)
Parte 3 -depende_de→ Parte 1
El contexto cubre: ✓ conjunto de datos  ✓ proporción de prueba  ✓ prueba intocable
```

Las aristas que el regex encontró en todo el enunciado:

```
Parte 3 → Parte 1
El reporte → Parte 2, Parte 3
```

RAG plano: 0 de 3 hechos. Con el salto: 3 de 3.

Ilustración 2. Salida de b_rag_plano.py: RAG plano contra el salto por la arista depende_de (Parte 0.b)

Es una falla de recuperación. Los datos y la partición están escritos en la Parte 1; el RAG plano trae la Parte 4 (0,293) y la Parte 3 (0,243) y cubre 0 de 3 hechos. Al seguir la arista depende_de Parte 3 → Parte 1 cubre 3 de 3 sin tocar el generador: el generador no puede usar lo que no recibió.

Qué haría un LLM con el primer contexto. Rellenar el hueco: suponer un dataset y una partición razonables y presentarlos con la misma seguridad que un dato del enunciado, sin avisar que faltaban. La sección 5 lo muestra con el solver real: sin grafo, el programador inventó las consultas de la Tarea C en una corrida y el corpus en la otra.

Por qué la arista se extrae con una regla. “La misma división de la Parte 1” es un patrón literal: una expresión regular lo encuentra siempre, igual en cada corrida y sin tokens. Un LLM puede omitir la arista o inventar otra, y si falla vuelve la misma pérdida de contexto sin ningún aviso. El LLM se reserva para lo que una regla no puede hacer (entidades y relaciones, capa 2).

Conclusión: la similitud entre la pregunta y un fragmento no mide si el fragmento contiene lo que la pregunta necesita. Una referencia explícita del enunciado es estructura, y la estructura se extrae con código.

- **0.c — Un returncode == 0 no es un experimento.** *Entregable: la salida y dos frases: qué otra fuga no detectaría la comprobación estática (piensa en un escalador ajustado con todos los datos), y por qué la decisión final puede quedar en manos de un LLM crítico si las comprobaciones de código van antes.*

```
stdout del experimento: Exactitud: 1.000
1) Evaluador ingenuo: APROBADO (returncode=0, resultados.json=sí)
2) Evaluador con dos comprobaciones de código:
  estática — se predice sobre lo mismo que se ajustó: ['X']
  plausible — métricas ≥ 0,999 en un problema con ruido: ['accuracy=1.0']
  → RECHAZADO: el programador recibe esto como retroalimentación y reintenta.
```

Ilustración 3. Salida de c_exit_cero.py: el evaluador ingenuo aprueba y las dos comprobaciones de código rechazan (Parte 0.c)

La fuga que la comprobación estática no ve. Un escalador ajustado con todos los datos antes de dividir (StandardScaler().fit_transform(X) y después train_test_split): el modelo se ajusta con X_tr y se evalúa con X_te, nombres distintos, y la exactitud (≈0,98) no llega al umbral de plausibilidad. Lo mismo una imputación o una selección de atributos ajustadas con todo. Nuestro crítico agrega una comprobación para el caso del escalador (ajuste_antes_de_dividir, solver/agentes/critico.py).

Por qué la decisión final puede quedar en un LLM crítico. Porque las comprobaciones de código van antes y no se pueden persuadir: el LLM solo ve lo que ya pasó los filtros, puede agregar rechazos pero no deshacer uno del código. En nuestro solver, además, un rechazo del LLM solo cuenta si cita una frase literal del enunciado; si la cita no existe, se descarta (rechazo_descartado).

Conclusión: terminar sin error y escribir un archivo es una condición necesaria, no la evidencia de un experimento correcto. Lo que se puede comprobar con código se comprueba primero; el LLM solo opina sobre lo demás.

2. Parte 1 — El solver multiagente

2.1 Arquitectura: ocho agentes y un orquestador

El orquestador (solver/orquestador.py) es un StateGraph de LangGraph 1.2.12. El ciclo programar → ejecutar → criticar → programar sale por aprobación o por tope de intentos; la salida a redactar

es por fin de la cola o por presupuesto. Las aristas del diagrama se leen del Mermaid que exporta LangGraph; las punteadas rojas son condicionales.

Orquestador (LangGraph): ocho agentes; aristas condicionales punteadas en rojo




Ilustración 4. Diagrama del orquestador (LangGraph) con sus aristas condicionales

#	Agente	Hace	Lo comprueba el código
1	Lector (agentes/lector.py)	PDF → secciones por tipografía, tablas, restricciones (formato, límites, secciones, archivos exigidos)	ligaduras, PDF escaneado, límites de una sola parte
2	Indexador (agentes/indexador.py, graphrag.py)	esqueleto por regla + capa 2 (entidades, notas, embeddings, comunidades)	aristas depende_de por regla
3	Planificador (agentes/planificador.py)	subtareas con tipo, dependencias y criterio	DAG, ids, cobertura, coherencia con el grafo
4	Investigador (agentes/investigador.py)	contexto de cada subtaska, con citas	la sección literal y sus dependencias van siempre
5	Programador (agentes/programador.py)	un script por subtaska de cálculo	la guarda del sandbox
6	Ejecutor (agentes/ejecutor.py)	corre el script en el sandbox	— (es código)
7	Crítico (agentes/critico.py)	aprueba o devuelve con la corrección	código de salida, contrato, NaN, figuras, fugas, plausibilidad
8	Redactor (agentes/redactor.py, formatos.py)	Markdown, PDF con límite de páginas o notebook ejecutado	secciones, extensión, procedencia

Tabla 1. Los ocho agentes y lo que el código comprueba de cada uno

El contrato es el del enunciado: `Solver().solve(ruta_pdf, carpeta_salida)` devuelve status, entregables, subtareas, usage, model y trace; `Solver().run(pregunta)` expone el contrato del Taller 4.

2.2 Las seis correcciones, señaladas en el código

	Corrección	Dónde	Evidencia
C 1	El plan es un DAG validado por código	planificador.validar() (ids, dependencias, ciclos, cobertura, aristas del grafo) y ordenar(); _tras_planificar devuelve el plan inválido con sus problemas (máx. 3)	traza: plan_invalido / plan_valido
C 2	GraphRAG con esqueleto determinístico	capa 1: indexador.esqueleto() (referencia, “la pregunta anterior”, anáfora “los dos modelos”); capa 2: graphrag.py (entidades del LLM, fusión por nombre normalizado con las notas del curso, bge-m3, comunidades de Louvain con resumen); graphrag.búsqueda_local() con citas	grafo.png, grafo_entidades.png, traza: capa2, grafo+capa2
C 3	Sandbox	sandbox/guarda.py (AST: red, procesos, borrado, eval, importlib, rutas fuera, URLs como descarga); ejecutor.py: entorno vacío, carpeta propia, start_new_session + killpg al vencer el tiempo	Parte 3
C 4	Contrato de resultados y crítico que mira antes	resultados.json obligatorio; critico.comprobar() primero, revisar_con_llm() solo si pasan	traza: rechazado con por: codigo o por: llm
C 5	Procedencia	procedencia.verificar() en _verificar: las cifras sin origen vuelven al redactor por su nombre; al último intento se marcan [cifra sin respaldo]	traza: devuelto_al_redactor, cifras_marcadas
C 6	Traza en todo camino	traza.py (una línea por evento, escrita al momento, con secretos enmascarados); _nodo atrapa todo error y lo registra; toda corrida termina en cerrar con fin	traza.jsonl de cada corrida

Tabla 2. Las seis correcciones no negociables y dónde viven

2.3 El grafo del enunciado de la Tarea A

Las aristas depende_de (en rojo) salen de reglas: “la misma división de la Parte 1” (referencia) y “los dos modelos” (anáfora, que lleva la Parte 2 a la Parte 3; sin ella, el 2026-10-04 la curva se entrenó sin estandarizar).

Grafo del enunciado — aristas depende_de (rojo), extraídas por regla




Ilustración 5. Grafo del enunciado de la Tarea A, con las aristas depende_de

La capa 2 agrega las entidades que extrae el LLM y su fusión con las notas del curso (31 fragmentos, 344 entidades, 12 comunidades, construidas una sola vez y guardadas en caché):




Ilustración 6. Capa 2 de la Tarea A: entidades del enunciado fusionadas con las notas del curso

2.4 Un plan

El plan que produjo el planificador para la Tarea A en la corrida completo-r1:

```
{
  "subtareas": [
    {
      "id": "T1",
      "tipo": "calculo",
      "secciones": [
        "Parte 1"
      ],
      "depende_de": [],
      "objetivo": "Cargar el conjunto Breast Cancer Wisconsin (Diagnostic) con sklearn.datasets.load_breast_cancer, reportar el número de ejemplos, de atributos y de casos de cada clase, y crear la división entrenamiento/prueba 70/30 estratificada por clase con random_state=42, que será la única división usada en toda la tarea.",
      "criterio": "Existen las cifras de ejemplos totales, atributos y conteo por clase, y los conjuntos de entrenamiento y prueba (70/30 estratificado, random_state=42) quedan disponibles para las subtareas siguientes.",
      "status": "pendiente",
      "intentos": 0
    },
    {
      "id": "T2",
      "tipo": "calculo",
      "secciones": [
        "Parte 2"
      ],
      "depende_de": [
        "T1"
      ],
      "objetivo": "Entrenar un Naive Bayes gaussiano y una regresión logística (con atributos estandarizados, ajustando el escalador solo con el entrenamiento) sobre la división de la Parte 1, y medir accuracy y F1 macro de cada modelo sobre el conjunto de prueba, presentados en una tabla.",
      "criterio": "Tabla con accuracy y F1 macro en prueba para ambos modelos (4 cifras en total), obtenidas
```

```

de la ejecución del código.",
  "status": "pendiente",
  "intentos": 0
},
{
  "id": "T3",
  "tipo": "calculo",
  "secciones": [
    "Parte 3"
  ],
  "depende_de": [
    "T1",
    "T2"
  ],
  "objetivo": "Sobre la misma división de la Parte 1, entrenar los dos modelos de la Parte 2 con el 5%, 10%, 25%, 50% y 100% del conjunto de entrenamiento (submuestras estratificadas, random_state=42), evaluar cada uno siempre sobre el mismo conjunto de prueba, y dibujar la exactitud contra el número de ejemplos de entrenamiento con una curva por modelo, guardando la figura como PNG.",
  "criterio": "Tabla de accuracy en prueba por tamaño de entrenamiento y por modelo (5 tamaños x 2 modelos) y archivo PNG con la figura de las dos curvas de aprendizaje.",
  "status": "pendiente",
  "intentos": 0
},
{
  "id": "T4",
  "tipo": "conceptual",
  "secciones": [
    "Parte 4"
  ],
  "depende_de": [
    "T2",
    "T3"
  ],
  "objetivo": "Discutir, usando las cifras de la Parte 2 y la curva de la Parte 3, si se observa el cruce que predicen Ng y Jordan, en qué tamaño de entrenamiento conviene cada modelo y por qué, relacionándolo con el sesgo y la varianza de un modelo generativo frente a uno discriminativo.",
  "criterio": "Texto de discusión que cite las accuracy por tamaño de entrenamiento y las métricas finales de prueba, identifique el punto de cruce (o su ausencia) y lo explique en términos de sesgo y varianza.",
  "status": "pendiente",
  "intentos": 0
}
]
}

```

Ilustración 7. pLan.json de la Tarea A (completo-r1): cuatro subtareas con tipo, dependencias y criterio

2.5 Una traza con un rechazo del crítico

Corrida corridas/completo-r2/tarea-C (2026-10-04): el programador de la T3 razonó hasta el tope de 32 768 tokens sin responder; con 65 536 entregó un script que no compilaba; la guarda lo detuvo y el crítico lo rechazó por código; el siguiente intento agotó el presupuesto y el redactor entregó con la reserva declarando lo que faltó. La traza completa está en el repositorio; este es el extracto de esa subtask:

- tipo: calculo · secciones: ['Parte 3'] · depende de: ['T1', 'T2']
- objetivo: Identificar por método en qué consultas falla (documento relevante fuera del top 3) y calcular los términos que comparten cada consulta con su documento relevante (y con los documentos recuperados en el top 3) para sustentar el análisis.
- criterio: Lista de consultas falladas por TF-IDF y por LSA (relevante fuera del top 3) y una tabla/listado de términos compartidos entre cada consulta y su documento relevante, obtenidos de los rankings de T1 y T2.
- status final: **pendiente**

Archivos

- contexto del programador: cache_solver/contextos/T3.md (16453 car.)

- RECHAZADO cache_solver/rechazados/T3/intento-1/: script.py

Eventos, en orden

- #29 **investigador** → grafo+capa2 · semillas=['análisis por consulta', 'documento relevante', 'top 3', 'consultas', 'términos compartidos', 'recuperación', 'ranking léxico'] · caracteres=7799: citas: ['Preámbulo', 'Parte 3', 's2-rag-y-vector-search § 5. Retrieval: Sparse, Dense, Hybrid ... 5.4 Reranking', 'comunidad 1', 'comunidad 10']
- #30 **programador** llamada: 6864 → 32768 tokens, max_tokens=32768, fin=length, 144.2 s · **error: contenido vacío (fin=length)**
- #31 **programador** llamada (reintento 2 del cliente): 6864 → 55586 tokens, max_tokens=65536, fin=stop, 235.43 s
- #32 **ejecutor** intento 1: returncode=None, 0.01 s, archivos=[] · **error: guarda: el código no compila: closing parenthesis '}' does not match opening parenthesis '[' (línea 236)**
- #33 **crítico** → rechazado · por=codigo: - guarda: el código no compila: closing parenthesis '}' does not match opening parenthesis '[' (línea 236)
- #34 **programador** llamada: 13922 → 32768 tokens, max_tokens=32768, fin=length, 117.92 s · **error: contenido vacío (fin=length)**
- #35 **programador** → presupuesto_agotado: consumido=284141 de 300000 (reserva 30000)

Otro rechazo, de corridas/completo-r1/tarea-A, es un **falso positivo**: la comprobación estática de fuga rechazó la T2 porque, además de evaluar en prueba, el script calculaba la exactitud en entrenamiento como diagnóstico. Costó un intento (~70 s). Lo dejamos así porque la comprobación es conservadora a propósito.

Conclusión: ningún paso del solver confía en que el modelo haya hecho bien su parte: el plan, el código, el resultado y cada cifra pasan por una comprobación en código antes de avanzar, y cada decisión queda en la traza.

3. Parte 2.a — El golden set

- **El golden set es el verificador.** Parte de `golden_tareas.json` (las tres tareas de práctica, 25 comprobaciones) y añade tus dos tareas reales o más, cada una con al menos cinco comprobaciones; entre todas, un notebook, un PDF y una trampa.

`golden/golden_tareas.json` parte de las 25 comprobaciones del kit (A, B, C) y agrega 22: **A09** y dos tareas reales de *Matemáticas y Programación para IA* (S1, telemetría de servidores, 9 comprobaciones; S2, comparación pareada de dos modelos, 12). La Tarea D del kit queda fuera: su paquete no está en el repositorio. Toda verdad se calcula (`verdad_py`, `golden/verdades_reales.py`) y cada comprobación lleva su `_por_que`; la tabla completa está en el Anexo A.

- **La trampa (S210–S211).** El intervalo bootstrap de S2 exige `default_rng(20260829)` y remuestrear tiendas completas: lo correcto es `[-0,194; 1,006]`. Remuestrear A y B por separado da `[-1,169; 2,000]`; usar la semilla global antigua da `[-0,169; 0,994]`. Las dos violaciones fallan con tolerancia 0,005. Una trampa secundaria (S106) separa la desviación de NumPy (`ddof=0`) de la de pandas (`ddof=1`).
- **A09.** El kit no detectaba la curva de aprendizaje sin estandarizar: A09 (0,9766 al 50 %) falla en esa corrida y pasa en las correctas.

- **Formato.** Hay notebook (B), PDF con límite de páginas (C) y archivos exigidos en output/ (S1, S2).

Lo que el golden no ve. Las corridas finales mostraron tres límites, que declaramos en lugar de esconder:

1. **No mide completitud.** S2 aprobó 12 de 12 con status parcial: la Tarea 7 del enunciado (integrar el pipeline en una sola corrida) quedó sin resultado y ninguna comprobación la mira, porque el golden comprueba las cifras del entregable, no que se haya hecho todo lo pedido.
2. **La procedencia aprueba en vacío.** En `sin_grafo-r2/tarea-C` el reporte no tiene ninguna cifra y C08 aprueba (“sin cifras con dos o más decimales”). El juez de la Parte 4 lo rechazó, y tiene razón.
3. **El umbral de procedencia deja pasar cifras erróneas o inventadas.** En una corrida de desarrollo el notebook de B publicó una divergencia KL de “5.0069” cuando la medida era 5.0069e-05; B09 aprobó con 81 de 82 cifras respaldadas (umbral 0,85). La atrapó nuestra C5, no el golden (sección 5, caso 2). Y en la prueba adversarial de la Parte 4, un reporte con tres cifras de LSA inventadas aprobó C08 con 24 de 27 (0,89): solo C06, que calcula la verdad, lo detectó.

Además, S103 tiene una limitación conocida del evaluador del kit, documentada en el Anexo A: acepta un encabezado de hasta 40 caracteres más que el nombre buscado, así que “Tarea 2 - Normalizar y calcular un indicador de carga” no se reconoce como “Tarea 2”.

Conclusión: el golden set detecta lo que fue diseñado para detectar (cifras, forma, la trampa), y sus tres huecos son de diseño, no de cálculo: mide lo que hay en el entregable, no lo que falta ni lo que sobra.

4. Parte 2.b — Solver completo contra la ablación “sin grafo”

- *Sobre tu solver completo y sobre al menos una ablación, con el mismo golden set y el mismo modelo: comprobaciones aprobadas, procedencia, subtareas fallidas, intentos de código, tokens de entrada y de salida por agente, y duración.*

SolverSinGrafo es el mismo solver con el investigador de la 0.b: recibe los dos fragmentos del enunciado más parecidos por TF-IDF y nada más, sin aristas, sin capa 2 ni notas del curso. Mismo golden (tareas A, B y C), mismo modelo, dos repeticiones por variante. Las tareas reales S1 y S2 se corrieron una vez, solo con el solver completo (tabla al final de esta sección).

Generado por `scripts/tablas_2b.py` desde los CSV de `evaluar_solver.py` y las trazas. Con repeticiones: media (mínimo–máximo).

Corridas: **completo** = `corridas/final/completo-r1`, `corridas/final/completo-r2`; **sin_grafo** = `corridas/final/sin_grafo-r1`, `corridas/final/sin_grafo-r2`

1. Por tarea

tarea	variante	comprobaciones (por repetición)	procedencia	status	subtareas no logradas	intentos de código	tokens entrada	tokens salida	duración (s)
A	completo	9/9 · 9/9	1.00 · 0.96	completado · completado	0	3	28496 (28430–28561)	53836 (50756–56916)	286 (265–306)
A	sin_grafo	9/9 · 9/9	1.00 · 1.00	completado · completado	0	3.5 (3–4)	24096 (20059–28132)	36168 (30143–42193)	257 (197–318)
B	completo	9/9 · 9/9	1.00 · 1.00	completado · completado	0	3	28990 (26680–31300)	46598 (44698–48498)	239 (223–254)
B	sin_grafo	9/9 · 9/9	1.00 · 1.00	completado · completado	0	3	22850 (19630–26071)	46453 (36692–56214)	322 (245–400)
C	completo	8/8 · 8/8	1.00 · 1.00	completado · completado	0	4 (3–5)	67856 (66251–69462)	168958 (130299–207618)	1005 (873–1137)
C	sin_grafo	7/8 · 5/8	1.00 · 1.00	parcial · parcial	2.5 (2–3)	4 (3–5)	33923 (26501–41345)	192928 (61596–324259)	1308 (462–2154)

2. Totales por variante (todas las tareas)

variante	repeticiones	comprobaciones	subtareas no logradas	intentos de código	tokens entrada	tokens salida	duración (s)
completo	2	26/26 · 26/26	0	10 (9–11)	125342 (124572–126112)	269392 (225753–313032)	1529 (1361–1698)
sin_grafo	2	25/26 · 23/26	2.5 (2–3)	10.5 (10–11)	80869 (80704–81034)	275548 (160003–391094)	1888 (1180–2596)

3. Tokens por agente (todas las tareas)

variante	agente	llamadas	tokens entrada	tokens salida	% del total
completo	critico	9	46802 (45365–48238)	16308 (14619–17998)	16 %
completo	indexador	12	4788	29964 (26441–33487)	9 %
completo	planificador	3	3377	7164 (6689–7640)	3 %
completo	programador	11 (10–12)	45741 (40162–51320)	195568 (148519–242616)	61 %
completo	redactor	3.5 (3–4)	24634 (18389–30880)	20388 (14670–26106)	11 %
sin_grafo	critico	8.5 (8–9)	35663 (33827–37499)	20422 (19522–21321)	16 %
sin_grafo	planificador	3	3377	6744 (4214–9273)	3 %
sin_grafo	programador	12 (10–14)	25640 (19705–31576)	213476 (86550–340401)	67 %
sin_grafo	redactor	4 (3–5)	16188 (12254–20123)	34908 (26957–42859)	14 %

Los tokens de **salida** incluyen el razonamiento del modelo: el de la H200 razona siempre.

4. Comprobaciones que fallan (insumo de la 2.c)

variante	tarea	check	tipo	en qué repeticiones
sin_grafo	C	C04	cifra	r2: verdad=0.8611 ±0.006; no hallada
sin_grafo	C	C05	cifra	r2: verdad=0.8333 ±0.006; no hallada
sin_grafo	C	C06	cifra	r1: verdad=0.7500 ±0.006; no hallada / r2: verdad=0.7500 ±0.006; no hallada

5. Costo fijo: el índice de las notas del curso

Se construye una vez y queda en caché; no está en las trazas de las tareas.

clave	modelo	creado	duración (s)	tokens entrada	tokens salida	fragmentos	entidades	comunidades
277d8a6398f1	zai-org/GLM-5.3-Flash	2026-10-04 21:39:18	319.6	37359	210868	31	344	12

Qué compró el grafo, en comprobaciones. Con grafo, 52 de 52 comprobaciones (26/26 en las dos repeticiones); sin grafo, 48 de 52 (25/26 y 23/26). Las cuatro que se pierden están en la Tarea C y en

ninguna otra: A y B son tareas en que cada parte trae sus propios datos, y el RAG plano ya recupera lo necesario. C es la única cuyo enunciado reparte la información en tres tablas (corpus, consultas y juicios, y la Parte 1 que pide el cálculo), y el TF-IDF top-2 siempre deja fuera una. Sin grafo C quedó parcial en las dos repeticiones, con 2 y 3 subtareas no logradas.

Qué compró, en tokens. El grafo cuesta contexto: con grafo se gastan 125 342 tokens de entrada contra 80 869 sin él (+55 %), y el indexador consume el 9 % del total. Pero no ahorra salida: 269 392 contra 275 548, porque sin el contexto correcto el programador razona más y produce menos (en sin_grafo-r1/tarea-C, 324 259 tokens de salida y 36 minutos para terminar parcial). En tiempo total, con grafo es un 19 % más rápido (1 529 s contra 1 888 s). A eso se suma un costo fijo que no está en las tablas por tarea: el índice de las notas, 248 227 tokens y 320 s, una sola vez.

Lo que no se puede afirmar. Con dos repeticiones la varianza de sin_grafo es enorme (160 003 a 391 094 tokens de salida): las cifras de costo son indicativas. Lo que sí es firme es el mecanismo, porque se repitió con causa visible en la traza: en r1 el contexto de la T1 de C traía el corpus pero no las consultas, y en r2 las consultas pero no el corpus (sección 5, caso 1).

tarea	status	comprobaciones	subtareas	intentos de código	tokens entrada	tokens salida	duración (s)
S1 (telemetría de servidores)	completado	8/9	5	5	59 328	122 636	984
S2 (comparación pareada)	parcial	12/12	11	7	114 383	386 137	3 002

Tabla 3. Tareas reales con el solver completo (resultados/final/resumen_reales_r1.csv, corridas/final/reales-r1)

En S1 la única comprobación que falla es S103, por la limitación del evaluador descrita en la 2.a. S2 resolvió la trampa del bootstrap (S210–S211) y aprobó todas sus cifras, pero quedó parcial: la T7 razonó hasta el tope tres veces y el freno de presupuesto detuvo el trabajo a 460 187 de 500 000 tokens; el redactor entregó con la reserva y declaró en la primera línea que la Tarea 7 no tiene resultado. En S2 el grafo no aportó aristas (sus siete tareas son independientes) ni fusiones con las notas del curso (0 entidades fusionadas: las notas hablan de LLM y RAG, no de bootstrap).

Conclusión: el grafo no es una mejora universal. Compra la sección literal y sus dependencias cuando el enunciado reparte la información entre partes (C), y ahí decide entre aprobar y fallar; cuando cada parte es autocontenida (A, B, S2) cuesta contexto y no cambia el resultado.

5. Parte 2.c — Las tres peores comprobaciones

- Las tres comprobaciones peores de tu solver y, para cada una, el agente al que apunta, con la traza como evidencia: qué recibió, qué produjo, qué decidió el código.

Las tres se eligieron de la tabla 4 de la 2.b y de las corridas de desarrollo que motivaron cambios en el solver. Cada extracto sale de scripts/evidencia.py sobre la traza de la corrida.

Caso 1 — C06 (y C04, C05) sin grafo: el investigador entrega un contexto incompleto

Comprobación. C06, el MRR de LSA en la Tarea C, falla en las dos repeticiones sin grafo; en r2 fallan también C04 y C05. **Agente señalado: investigador** (en la variante sin grafo), con el programador como el que rellena el hueco.

Qué recibió. El contexto de la T1 tenía 8 670 caracteres con grafo (la Parte 1, las tres tablas y las notas sobre BM25) y 1 407 y 823 sin él:

corrida	contexto de la T1	qué faltó	qué hizo el programador	qué decidió el código
completo-r1	Parte 1 + 3 tablas + notas	nada	—	aprobada al primer intento
sin_grafo-r1	Parte 1 + Corpus (sim. 0,547 y 0,239)	las consultas	inventó sus propias consultas	el crítico LLM lo rechazó citando q5 literal; T2 falló tres veces en el tope de razonamiento; T3 omitida
sin_grafo-r2	Parte 1 + Consultas (sim. 0,574 y 0,269)	el corpus	reescribió los diez documentos	rechazado 3 de 3 citando el texto real de d02 y d03; T2 y T3 omitidas

Tabla 4. El contexto de la T1 de la Tarea C en las tres variantes (*cache_solver/contextos/T1.md* de cada corrida)

Qué produjo y qué se publicó. En r2 el redactor no tuvo ninguna cifra medida y lo declaró (“La subtarea T1 no tiene resultado: no se reportan sus cifras”); el reporte no contiene ninguna cifra inventada. Es la falla de la 0.b medida en el solver real: el RAG plano no pierde “algo de contexto”, pierde la tabla que la subtarea necesita, y el programador la rellena con datos plausibles. Lo que contuvo el daño fue el crítico (C4), que tiene el enunciado completo y cita la frase que el script viola.

Caso 2 — C08 en desarrollo: el redactor publica una cifra que nadie midió

Comprobación. C08 (procedencia de la Tarea C) falló en corridas/desarrollo/final-completo-r1-sin-F3F4 con 7 de 9 cifras respaldadas (0,78). **Agente señalado: redactor.**

Qué recibió y qué produjo. Las cifras medidas en resultados.json. El redactor escribió 0.6140 donde la medida era 0.61405098 (truncó en lugar de redondear: lo correcto es 0.6141). Escribió también 39.53 %, que sí era una medida (0.39534) expresada como porcentaje. En la misma corrida, el notebook de B escribió una divergencia KL de “5.0069” cuando la medida era 5.0069e-05, y en la misma frase dijo que era “prácticamente nula”.

Qué decidió el código. La procedencia (C5) devolvió las cifras al redactor por su nombre tres veces seguidas (devuelto_al_redactor: “[‘0.6140’, ‘39.53 %’]” en C y “[‘5.0069’]” en B), y el redactor las repitió las tres veces: sin decirle cuál era la cifra correcta, no supo corregirla. Al agotar los intentos el reporte se publicó con ellas. El golden atrapó la de C (C08) pero no la de B, que aprobó B09 con 81 de 82 cifras. Y uno de los dos rechazos de C era nuestro: el 39.53 % estaba bien y la procedencia no lo reconocía porque buscaba el porcentaje en una sola de sus dos lecturas (39.53 o 0.3953).

Qué cambiamos. F3: la procedencia lee notación científica, acepta un porcentaje si cualquiera de sus dos lecturas está respaldada y devuelve sugerencias concretas (“¿quisiste decir 0.6141?”, “la medida es 5.0069e-05”). F4: al último intento, las cifras que siguen sin respaldo se marcan [cifra sin respaldo] en el entregable en lugar de publicarse limpias. En las corridas finales la procedencia fue 1,00 en todas las tareas salvo una (0,96, completo-r2 A).

Caso 3 — S103: la única comprobación que falla el solver completo

Comprobación. S103 (secciones de S1: “Tarea 1” a “Tarea 5”, en orden) falla en reales-r1: “faltan: [‘Tarea 2’]”. **Agente señalado: redactor**, pero la causa está en el verificador.

Qué recibió y qué produjo. El enunciado pide una sección por tarea y titula cada una con su nombre completo; el redactor escribió ## Tarea 2 - Normalizar y calcular un indicador de carga. El evaluador del kit acepta un encabezado de hasta 40 caracteres más que el nombre buscado: este se pasa por 4. La Tarea 3 entra justo en el límite.

Qué decidió el código. Nada que corregir en el solver: el encabezado es el que pide el enunciado. Probamos las dos formas de escribir la comprobación (los títulos completos y “Tarea N”) y ninguna acepta los dos estilos de encabezado; dejamos “Tarea N” y documentamos la limitación. Es el caso que el enunciado anticipa: cuando el solver completo no falla, el problema es el golden set.

Conclusión: los tres peores casos apuntan a tres agentes distintos (investigador, redactor, verificador), y en los tres la traza permite ver qué recibió cada uno. El patrón común es que el modelo no deja huecos: cuando le falta un dato lo inventa, y cuando una cifra se le devuelve, la repite. Lo que funcionó fue el código que lo rodea.

6. Parte 3 — Los cuatro frenos, forzados

- *Implementa cuatro frenos y demuestra cada uno forzándolo: una corrida que lo dispare y su traza. Para forzarlos sin gastar, un modelo de guion sirve.*

Los cuatro se fuerzan con un modelo de guion (`scripts/forzar_frenos.py`): los frenos, el sandbox y la traza son los del solver real. Dónde vive cada uno: `solver/frenos.py`.

Generado por `scripts/forzar_frenos.py` con un modelo de guion (sin H200): los frenos, el sandbox y la traza son los del solver real. Cada carpeta tiene su `traza.jsonl` completa.

presupuesto — disparado

`corridas/frenos/presupuesto/` · status **parcial** · subtareas {'T1': 'aprobada (1 intentos)', 'T2': 'pendiente (0 intentos)'} · entregables ['reporte.md'] · tokens {'tokens_entrada': 800, 'tokens_salida': 400}

- #13 programador → **presupuesto_agotado** [T2]: consumido=900 de 1500 (reserva 600)
- #14 orquestador → **presupuesto_agotado** []: programador: presupuesto agotado (900 tokens)
- #15 redactor redacta (200+100 tokens); recibió la orden de declarar: “- La subtask T2 (Parte 2) no tiene resultado (pendiente): no se reportan sus cifras.
- El presupuesto de tokens se agotó: se entrega lo que se alcanzó a medir.”

repeticion — disparado

`corridas/frenos/repeticion/` · status **parcial** · subtareas {'T1': 'aprobada (1 intentos)', 'T2': 'fallida (3 intentos)'} · entregables ['reporte.md'] · tokens {'tokens_entrada': 7000, 'tokens_salida': 1400}

- #15 critico → **rechazado** [T2]: - plausibilidad: métricas $\geq 0,999$ en un problema con ruido: ['accuracy=1.0']
- fuga: se evalúa sobre las mismas variables con que se ajustó: ['X']
- #17 ejecutor → **script_repetido** [T2]: idéntico (1f1ca7597eb7285e) a uno ya rechazado: no se ejecuta
- #18 critico → **rechazado** [T2]: - script idéntico a uno ya rechazado: no se ejecutó
- #20 ejecutor → **script_repetido** [T2]: idéntico (1f1ca7597eb7285e) a uno ya rechazado: no se ejecuta
- #21 critico → **rechazado** [T2]: - script idéntico a uno ya rechazado: no se ejecutó
- #22 orquestador → **tope_intentos** [T2]: 3 intentos: la subtask queda fallida y la cola sigue
- #23 redactor redacta (1000+200 tokens); recibió la orden de declarar: “- La subtask T2 (Parte 2) no tiene resultado (fallida): no se reportan sus cifras.”

timeout — disparado

corridas/frenos/timeout/ · status **completado** · subtareas {'T1': 'aprobada (1 intentos)', 'T2': 'aprobada (2 intentos)'} · entregables ['reporte.md'] · tokens {'tokens_entrada': 7000, 'tokens_salida': 1400}

- #14 ejecutor, intento 1 [T2]: returncode=-9, 3.01 s, error: timeout: superó 3 s y se mató el grupo de procesos
- #15 critico → **rechazado** [T2]: - timeout: superó 3 s y se mató el grupo de procesos
- #20 redactor redacta (1000+200 tokens)

red — disparado

corridas/frenos/red/ · status **parcial** · subtareas {'T1': 'aprobada (1 intentos)', 'T2': 'fallida (1 intentos)'} · entregables ['reporte.md'] · tokens {'tokens_entrada': 5000, 'tokens_salida': 1000}

- #14 ejecutor → **confirmacion_red** (aprobado=False) [T2]: T2: el script quiere descargar (línea 2: import fetch_openml; línea 3: fetch_openml())
- #15 ejecutor, intento 1 [T2]: returncode=None, 0.0 s, error: descarga no confirmada por una persona: línea 2: import fetch_openml; línea 3: fetch_openml()
- #17 orquestador → **tope_intentos** [T2]: 1 intentos: la subtask queda fallida y la cola sigue
- #18 redactor redacta (1000+200 tokens); recibió la orden de declarar: “- La subtask T2 (Parte 2) no tiene resultado (fallida): no se reportan sus cifras.”

El freno de presupuesto, con el modelo real. Se disparó dos veces sin forzarlo: en corridas/completo-r2/tarea-C (2026-10-04, sección 2.5) y en la tarea real S2 de las corridas finales, donde la T7 consumió tres llamadas en el tope de razonamiento y el trabajo se detuvo a 460 187 de 500 000 tokens (presupuesto_agotado, eventos 60 y 61 de corridas/final/reales-r1/tarea-S2/traza.jsonl). El redactor usó la reserva de 50 000 y entregó el informe con la nota: “La subtask T7 no tiene resultado (pendiente): no se reportan sus cifras. El presupuesto de tokens se agotó”.

Conclusión: los cuatro frenos se disparan y dejan su rastro en la traza. El de presupuesto es el que más importa con este modelo, porque su modo de falla habitual es razonar hasta el tope sin entregar nada.

7. Parte 4 — Extensión E: un juez de otra familia

- *El reporte lo califica un LLM de otra familia (gemma3 en el Ollama de la H200) contra la rúbrica del enunciado, calibrado contra tus comprobaciones determinísticas: acuerdo y kappa.*

scripts/juez.py le da a gemma3:27b el enunciado y el entregable de cada corrida de la 2.b, y le hace las preguntas del campo juez del golden: las mismas comprobaciones, sin la cifra verdadera. Su veredicto se compara con el de evaluar_solver.py.

Juez gemma3:27b (Ollama de la H200) contra el golden determinístico (evaluar_solver.py).
Generado por scripts/juez.py el 2026-10-05.

Costo: 36587 tokens de entrada, 3487 de salida, 1194 s.

Acuerdo global

- comprobaciones juzgadas: **74** (sin respuesta del juez: 6)

- acuerdo: **0.986** · kappa de Cohen: **0.882**

	juez: aprueba	juez: rechaza
golden: aprueba	69	1
golden: rechaza	0 (falso positivo del juez)	4

Formato de las respuestas del juez (se pidió {"ok", "razon"} en todas): completo 68, sin_razon 6, faltante 6.

Por tipo de comprobación

tipo	n	acuerdo	kappa	falsos positivos del juez
cifra	20	1.00	1.00	0
cifra_presente	20	1.00	—	0
contiene	7	1.00	—	0
paginas_max	4	1.00	—	0
palabras_max	4	1.00	—	0
procedencia	11	0.91	0.00	0
secciones	8	1.00	—	0

Donde el juez aprueba lo que el golden rechaza

Ninguno.

Dónde acierta. Acuerdo 0,986 y kappa 0,882 sobre 74 comprobaciones, sin falsos positivos: rechazó las cuatro cifras que el golden rechaza (C06 en sin_grafo-r1; C04, C05 y C06 en sin_grafo-r2). El único desacuerdo es C08 de sin_grafo-r2, donde el juez rechaza una procedencia que el golden aprueba en vacío, y el juez tiene razón (2.a).

Por qué esas cifras no prueban lo que parecen. En los cuatro rechazos el redactor había escrito que esas cifras no se reportaban: el juez leyó la declaración (“el reporte indica explícitamente que la ejecución de LSA falló”), no detectó la falta. Sus razones para aprobar son de coherencia, no de corrección: “0.8611 parece plausible dado los resultados por consulta”, “aunque no cuento las palabras exactamente, el reporte parece estar dentro del límite”. Por eso le quitamos esa ayuda con una prueba adversarial: el reporte de sin_grafo-r1/tarea-C, adulterado a mano con un MRR de LSA inventado (0,8056; la verdad es 0,7500), coherente con su propia tabla y sin ningún rastro de la falla (scripts/juez_adversarial.py, en corridas/desarrollo/juez-adversarial). Lo que el juez respondió sobre ese reporte:

Juez gemma3:27b (Ollama de la H200) contra el golden determinístico (evaluar_solver.py). Generado por scripts/juez.py el 2026-10-05.

Costo: 2599 tokens de entrada, 308 de salida, 93 s.

Acuerdo global

- comprobaciones juzgadas: **7** (sin respuesta del juez: 0)
- acuerdo: **0.857** · kappa de Cohen: **0.000**

	juez: aprueba	juez: rechaza
golden: aprueba	6	0
golden: rechaza	1 (falso positivo del juez)	0

Formato de las respuestas del juez (se pidió {"ok", "razon"} en todas): completo 7, sin_razon 0, faltante 0.

Por tipo de comprobación

tipo	n	acuerdo	kappa	falsos positivos del juez
cifra	3	0.67	0.00	1
contiene	1	1.00	—	0
paginas_max	1	1.00	—	0
procedencia	1	1.00	—	0
secciones	1	1.00	—	0

Donde el juez aprueba lo que el golden rechaza

- adulterado r1 · C C06 (cifra): golden “verdad=0.7500 ±0.006; no hallada” · juez “El reporte indica un MRR de 0.8056 para LSA, lo cual es consistente con los resultados presentados en la tabla.”

El resultado: el juez aprobó la cifra inventada. Respondió que “el reporte indica un MRR de 0.8056 para LSA, lo cual es consistente con los resultados presentados en la tabla”, y aprobó también la procedencia porque las cifras tienen “valores decimales que sugieren cálculos precisos y no estimaciones”. Es exactamente el modo de falla de la 0.a, ahora en el verificador: una cifra con aspecto de medida pasa por medida. Comprobó que la cifra coincidiera con la tabla del propio reporte (la inventamos coherente a propósito), no con el experimento; sin ejecutar el código no tiene cómo saber que el MRR verdadero es 0,7500. El golden la rechazó con C06, la comprobación que calcula la verdad. Pero su comprobación de procedencia también falló: C08 aprobó con 24 de 27 cifras respaldadas (0,89), porque tres cifras inventadas quedan por debajo del umbral de 0,85. Lo que detectó la falsificación fue la cifra calculada, no ninguna de las dos formas de procedencia.

Qué costó y qué tan estable es. 36 587 tokens de entrada y 3 487 de salida en 20 minutos (12 llamadas de ~100 s). El formato pedido ({"ok", "razon"}) no se respetó en 12 de 80 respuestas, siempre en la Tarea B (el notebook, la entrada más larga): seis veces solo con booleanos y seis sin la envoltura veredictos, con el mismo modelo, temperature=0 y casi el mismo entregable. Un juez que no da razones no se puede auditar.

Conclusión: el juez no reemplaza al verificador determinístico. Su kappa de 0,882 sobre las corridas de la 2.b mide un caso fácil: un solver que declara sus fallas. Ante una cifra inventada y coherente la aprueba, porque valida coherencia y no corrección. Sirve como segunda opinión sobre lo que el golden no mide (la forma, si se nombra la consulta que falla, una procedencia aprobada en vacío), no para decidir si una cifra es correcta. Y deja una lección también para nuestro golden: la procedencia por fracción con umbral deja pasar tres cifras inventadas; solo la cifra calculada las detecta.

8. Parte 5 — Reflexión

1. Dónde vive el objetivo: El sistema no considera una tarea terminada solo porque lo diga un modelo. Primero, revisa si el plan es válido. También comprueba las sugerencias del revisor automático y mantiene los rechazos que haya hecho el programa. El redactor prepara el texto, pero el coordinador decide si cumple con lo solicitado y si cada cifra tiene una fuente.

La tarea se da por terminada cuando todos los cálculos han sido aprobados, la redacción está lista y no hubo errores ni se agotó el tiempo disponible. Así, la decisión depende de reglas que se pueden revisar y probar.

2. Con resumen_solver.csv delante: El programador gasta más que todos: 61 % de los tokens con grafo y 67 % sin él, y casi todo es salida (195 568 de salida contra 45 741 de entrada con grafo), el modelo de la H200 razona antes de escribir cada script y ese razonamiento se cobra como salida. Al comparar con la versión sin grafo, se completaron cuatro comprobaciones más (52 frente a 48) y quedaron cinco subtareas menos sin resolver; todas eran de la Tarea C. A cambio, el consumo de entrada subió un 55 % (125 342 frente a 80 869 unidades), y el indexador representó el 9 % del gasto. El consumo de salida fue parecido: 269 392 frente a 275 548 unidades.

3. Uso honesto y daño: Usar el sistema de forma responsable significa decir que se utilizó el solver, conservar un registro de los pasos (qué recibió cada agente, qué produjo y qué decidió el sistema) y aclarar qué partes hizo la persona.

Al revisar las medidas de protección, encontramos dos formas de hacer cosas que no se detectaban: abrir archivos CSV desde internet y cargar una herramienta de conexión a la red de manera indirecta. Se corrigieron: ahora, si se incluye un enlace, el sistema pide autorización a una persona, y se bloqueó la carga de herramientas de esa forma.

Estas medidas tienen límites. Revisar el código no permite detectar todo lo que un programa pueda crear mientras funciona, y el sistema no bloquea por completo la conexión a internet. Ayudaron otras protecciones: el programa no recibe las variables confidenciales del archivo .env, trabaja en una carpeta propia, puede cerrarse junto con los procesos relacionados y pasa por comprobaciones antes de llamar al modelo.

Si estas protecciones fallaran, el código generado podría leer o borrar archivos de la persona, o enviar datos por internet.

9. Presupuesto, configuración y reproducibilidad

Presupuesto. Todo corrió en la H200 sin clave de API: 0 USD. Por corrida, el solver tiene un presupuesto de 500 000 tokens con 50 000 de reserva para el redactor, 3 intentos por subtask y 120 s por script (.env.example). Las tareas de práctica tomaron entre 3 y 36 minutos y entre 50 000 y 366 000 tokens; S2, 50 minutos y 500 520 tokens. El índice de las notas del curso costó 248 227 tokens una sola vez.

Reproducibilidad. El repositorio contiene el código, pyproject.toml, uv.lock y requirements.txt con versiones fijadas, el golden set, y cada corrida con su traza.jsonl, su plan.json y su entregable. Los CSV crudos del evaluador (resultados_solver.csv y resumen_solver.csv en el enunciado) están en resultados/final/ con el nombre de su variante y repetición (resultados_completo_r1.csv, resumen_sin_grafo_r2.csv, ...), para que ninguna corrida sobrescriba a otra. Ninguna clave de API aparece en el código, las trazas ni los scripts generados: .env está fuera de git y el sandbox corre con el entorno vacío.

```
uv sync && cp .env.example .env          # y la VPN
uv run pytest -q
uv run python golden/verdades_reales.py
bash scripts/corridas_2b.sh completo 1    # y 2; sin_grafo 1 y 2
bash scripts/corridas_2b.sh tablas
bash scripts/corridas_2b.sh frenos
bash scripts/corridas_2b.sh juez
uv run python scripts/juez_adversarial.py  # y los dos comandos de su docstring
uv run python scripts/diagrama_png.py
uv run python scripts/informe_word.py
```

Anexo A — El golden set, comprobación por comprobación

Generado por `golden/generar_readme.py` desde `golden_tareas.json`: cada comprobación lleva su `_por_que`.

```
# desde la RAÍZ del repo (las verdad_py de S1 y S2 importan golden/verdades_reales.py)
uv run python golden/verdades_reales.py          # verdades de S1 y S2 y lo que dan las violaciones
uv run python solver-v2/evaluar_solver.py --golden golden/golden_tareas.json --solo-evaluar
corridas/completo-r2 --solo A B C
```

Golden set del grupo (Taller 03 v2, Parte 2.a). Parte del golden del kit (`solver-v2/golden_tareas.json`, tareas A, B y C con sus 25 comprobaciones) y agrega: A09 (la curva de aprendizaje estandarizada, que el kit no comprobaba) y dos tareas reales de Matemáticas y Programación para IA (S1, S2) con 9 y 12 comprobaciones. La Tarea D del kit queda fuera: su paquete (`hackathon3_student`) no está en el repositorio. Entre todas: un notebook (B), un PDF (C) y la trampa (S210-S211: semilla y bootstrap pareado). Cada comprobación lleva en “`_por_que`” qué detecta; `evaluar_solver.py` ignora ese campo. Las `verdad_py` de S1 y S2 importan `golden/verdades_reales.py`: correr el evaluador DESDE LA RAÍZ del repo. Tipos de comprobación: ver el `_comentario` de `solver-v2/golden_tareas.json`. El campo “`juez`” es la pregunta, SIN la cifra verdadera, que la extensión (Parte 4, `scripts/juez.py`) le hace a un LLM de otra familia para medir su acuerdo con la comprobación.

A — `../solver-v2/enunciados/tarea-a-generativo-discriminativo.pdf` → `reporte.md` (9 comprobaciones)

id	tipo	qué detecta
A01	archivo	El entregable que pide el enunciado, con su nombre exacto.
A02	archivo	La Parte 3 exige la curva como figura PNG.
A03	secciones	Secciones exigidas por el enunciado, en su orden.
A04	palabras_max	Límite de 1 200 palabras.
A05	cifra_presente	Tamaño del dataset (569 ejemplos): detecta que se cargó el conjunto correcto.
A06	cifra	Exactitud de Naive Bayes sobre la partición 70/30 estratificada con semilla 42.
A07	cifra	Exactitud de la regresión logística estandarizada sobre la misma partición.
A08	procedencia	Procedencia: las cifras del reporte deben salir de una ejecución (respuesta a la 0.a).
A09	cifra_presente	NUEVA. Curva de aprendizaje, regresión logística ESTANDARIZADA con el 50 % del entrenamiento: 0.9766. Sin estandarizar da 0.9415 o 0.9532 según <code>max_iter</code> . El kit no detectaba el error de la corrida del 2026-10-04 (T3 sin estandarizar, “los dos modelos” de la Parte 2): A07 mide la Parte 2, no la curva. Se usa el 50 % porque 0.9766 no coincide con ninguna otra cifra de la curva (el 5 %, 0.9298, sí coincide con la LR sin estandarizar al 25 %).

B — `../solver-v2/enunciados/tarea-b-temperatura-top-p.pdf` → `*.ipynb` (9 comprobaciones)

id	tipo	qué detecta
B01	archivo	El entregable es un notebook.
B02	ipynb_ejecutado	El notebook se entrega EJECUTADO y sin errores.
B03	cifra_presente	Entropía (bits) con <code>T=0.5</code> : cifra exacta que el evaluador recalcula.
B04	cifra_presente	Entropía con <code>T=1</code> .
B05	cifra_presente	Entropía con <code>T=2</code> .
B06	cifra_presente	Masa de probabilidad renormalizada de <code>t0</code> tras <code>top-p</code> .
B07	contiene	Los tokens <code>t0...t3</code> del núcleo aparecen nombrados.
B08	archivo	La figura del muestreo existe (archivo o imagen embebida).
B09	procedencia	Procedencia de las cifras del notebook.

C — ../solver-v2/enunciados/tarea-c-recuperacion-lexica-lsa.pdf → reporte.pdf (8 comprobaciones)

id	tipo	qué detecta
C01	archivo	El entregable es un PDF.
C02	paginas_max	Límite de dos páginas.
C03	secciones	Secciones exigidas, en orden.
C04	cifra	MRR de TF-IDF.
C05	cifra	Hit@3 de TF-IDF.
C06	cifra	MRR de LSA con TruncatedSVD(4, random_state=0).
C07	contiene	La consulta que falla (q5) se nombra en el análisis.
C08	procedencia	Procedencia.

S1 — ../tareas/reales/semana1/enunciado.pdf → reporte.md (9 comprobaciones)

Matemáticas y Programación para IA, semana 1: telemetría con NumPy, Pandas y Parquet. Datos en tareas/reales/semana1/data/. Las verdades salen de golden/verdades_reales.py.

id	tipo	qué detecta
S101	archivo	Entregable principal.
S102	archivo	El enunciado exige el Parquet en output/ (Tarea 5). Ruta estricta: un archivo enterrado en la carpeta de una subtarea no cumple el entregable.
S103	secciones	“Una sección por tarea, en orden (Tarea 1 a Tarea 5)”, tal como lo dice el enunciado. LIMITACIÓN conocida del evaluador del kit: acepta un encabezado de hasta 40 caracteres más que el nombre buscado, así que “## Tarea 2 - Normalizar y calcular un indicador de carga” (51) no se reconoce y “## Tarea 2” sí. Con los títulos completos pasa lo contrario: ninguna lista acepta las dos formas (exploratoria y completo-r1, 2026-10-05). Un fallo aquí se revisa a mano antes de atribuirlo al solver.
S104	palabras_max	Máximo 800 palabras.
S105	cifra_presente	Media de gpu_utilization (57.9931): las tres características en el orden exigido.
S106	cifra_presente	TRAMPA SECUNDARIA. load_score de la fila 23 = 3.136218 con la desviación de NumPy (ddof=0), la que reproduce el “Resultado esperado”. Con la .std() de pandas (ddof=1) sale 3.130986: la tolerancia 0.002 separa los dos.
S107	cifra	Tabla resumen: potencia media de AI-SRV-01 (363.4598).
S108	cifra	Tabla resumen: carga media de AI-SRV-06 = 0.6676 (con ddof=1 sale 0.6665). Comprueba que la tabla está completa (los seis servidores), no solo la fila de ejemplo.
S109	procedencia	“Toda cifra del reporte debe provenir de una ejecución del código”.

S2 — ../tareas/reales/semana2/enunciado.pdf → informe.md (12 comprobaciones)

Matemáticas y Programación para IA, semana 2: comparación pareada de dos modelos. Contiene la TRAMPA del golden (S210-S211). El evaluador lee los números sin signo: las verdades negativas se escriben en valor absoluto.

id	tipo	qué detecta
S201	archivo	Entregable principal.
S202	archivo	Tabla pareada exigida en output/ (Tarea 7).
S203	archivo	Figura por tienda exigida en output/ (Tarea 3).
S204	secciones	Las cinco partes del Anexo, en orden.
S205	cifra_presente	Desviación estándar MUESTRAL de las diferencias (1.2534). Con ddof=0 sale 1.2136.
S206	cifra_presente	Error estándar = $sd/\sqrt{n}$ (0.3133).
S207	cifra_presente	p-value bilateral de la prueba t de una muestra sobre las diferencias (0.2013). Una prueba t independiente (no pareada) da otro valor.
S208	cifra_presente	p-value exacto por cambios de signo: 13 372 de 65 536 configuraciones (0.2040). La tolerancia lo separa del p de la prueba t (0.2013).

id	tipo	qué detecta
S209	contiene	La semilla del bootstrap se declara (pregunta 17).
S210	cifra_presente	TRAMPA. Límite inferior del bootstrap pareado: -0.1938 con default_rng(20260829) y tiendas completas. Remuestrear A y B por separado da -1.169; usar np.random.seed (la semilla global antigua) da -0.169. Las dos violaciones de la Tarea 6 fallan aquí.
S211	cifra_presente	TRAMPA. Límite superior: 1.0063 (separado: 2.000; semilla global: 0.9939).
S212	procedencia	"Toda cifra del informe debe provenir de una ejecución del código".

Validación sin gastar H200

- A09 aprueba en las corridas con la curva estandarizada (0.976608 en el resultados.json de la T3 de completo, completo-r1 y completo-r2) y **falla** en corridas/prueba/tarea-a-generativo-discriminativo/ (la T3 sin StandardScaler, 2026-10-04): la falla que el kit no veía.
- Las trampas de S2 se reproducen con python golden/verdades_reales.py (s2_trampas).
- En la exploratoria (2026-10-05) la T6 de S2 calculó el intervalo correcto [-0.19375, 1.00625] pero la corrida agotó el presupuesto antes de aprobarla: S210 y S211 fallaron por presupuesto, no por la trampa.