

Ejercicio de refuerzo - Semana 2

Comparación defendible de dos modelos sobre tiendas pareadas

Modalidad	Tiempo sugerido	Entrega
Individual	2-3 horas	Scripts, figura, CSV e informe.md

Versión adaptada para el solver (Taller 03 v2, MMIA 6013). El contenido técnico, los datos, las constantes y los resultados esperados son los del enunciado original del curso. Solo cambia la logística de entrega: no se usa Git, uv, pytest ni D2L; el informe.md se construye desde cero con las 18 preguntas que se listan en el Anexo, y los contratos de las pruebas públicas se escriben aquí como requisitos.

Objetivo

Construir una comparación estadística reproducible entre dos modelos evaluados sobre las mismas unidades. El ejercicio integra auditoría de pares, diferencias por tienda, efecto, incertidumbre, prueba t pareada, referencia exacta por cambios de signo, bootstrap pareado e interpretación limitada por la evidencia.

Escenario

Dos modelos de regresión ya entrenados, A y B, pronostican la demanda semanal de las mismas 16 tiendas. El archivo `data/model_errors.csv` (columnas `store_id`, `error_a`, `error_b`) contiene el error absoluto de cada modelo, medido en unidades vendidas. Un error menor representa un mejor pronóstico. Los mismos datos se reproducen en la tabla siguiente.

Procedencia y límite: los datos son sintéticos, deterministas y creados para esta actividad. No provienen de tiendas reales y no constituyen evidencia sobre una empresa, mercado o población existente.

store_id	error_a	error_b
S01	12.4	10.6
S02	9.8	9.1
S03	15.1	13.9
S04	11.0	12.4
S05	8.7	7.2
S06	13.6	13.9
S07	10.2	9.3
S08	14.9	12.8
S09	7.5	9.3
S10	16.0	15.0
S11	9.3	9.8
S12	12.8	11.1
S13	11.7	12.9
S14	8.9	8.3
S15	13.2	11.9
S16	10.6	11.5

Reglas de interpretación

- No ejecutar una prueba antes de completar la Parte 1 de informe.md.
- Toda respuesta debe citar resultados numéricos o elementos concretos de la figura.
- Una diferencia positiva favorece a B porque se define como error de A menos error de B.
- No reducir la conclusión a significativo o no significativo.

- No interpretar el p-value como la probabilidad de que la hipótesis nula sea verdadera.

$$d_i = e_A(i) - e_B(i) \quad \Delta = E(d_i) \quad H_0: \Delta = 0 \quad H_1: \Delta \neq 0$$

Tarea 1 - Completar el contrato de análisis

Responder las preguntas 1 a 10 del informe antes de calcular resultados: modelos, proceso objetivo propuesto, métrica y su dirección, unidad de análisis, evidencia de emparejamiento, estimando, hipótesis, procedimiento principal, resultados que acompañarán al p-value y límites del diseño.

Tarea 2 - Auditar los datos y construir los pares

Cargar el CSV validando que existan exactamente las columnas `store_id`, `error_a`, `error_b`; que cada identificador sea único y no nulo (si no, `ValueError` que mencione el identificador); y que los errores sean numéricos, finitos y no negativos (si no, `ValueError`). No modificar el CSV original.

Construir la tabla pareada: conservar las tres columnas originales y añadir `difference` ($= \text{error}_a - \text{error}_b$) y `favors` ("B" si la diferencia es positiva, "A" si es negativa). Verificar los pares mediante `store_id`; comprobar únicamente la longitud de dos vectores no demuestra que correspondan a las mismas tiendas.

Tarea 3 - Hacer visible la evidencia por tienda

Crear una figura que muestre una observación por tienda, el signo y la magnitud de `difference`, y una referencia visible en cero. Guardarla en `output/store_differences.png`. En el informe, identificar cuántas tiendas favorecen a cada modelo y las diferencias de mayor magnitud en ambas direcciones.

Tarea 4 - Calcular el efecto y su incertidumbre

Reportar exactamente `n`, `mean`, `sample_sd` y `standard_error` de las diferencias. La desviación debe ser muestral y $SE = s_d / \sqrt{n}$. Interpretar la diferencia media en unidades vendidas y distinguir la dispersión entre tiendas del error estándar de la media.

Con `scipy.stats` sobre el vector de diferencias, calcular la prueba t y un intervalo t bilateral del 95 % para la media pareada; conservar grados de libertad, estadístico, p-value e intervalo.

Tarea 5 - Comparar dos referencias nulas

Procedimiento principal: prueba t de una muestra sobre las diferencias, alternativa bilateral. Después, prueba exacta por cambios de signo: enumerar las 2^{16} configuraciones de signos y contar las medias nulas cuya magnitud sea al menos tan extrema como la observada. Reportar el total de configuraciones, el conteo de extremas y el p-value.

En el informe, explicar el p-value de forma condicional a la hipótesis nula, el diseño y los supuestos, y por qué la prueba t y los cambios de signo no son procedimientos intercambiables aunque produzcan resultados numéricos cercanos.

Tarea 6 - Realizar un bootstrap pareado

Usar `np.random.default_rng` con la semilla indicada y 10 000 remuestras. Remuestrear tiendas completas mediante el vector de diferencias; no remuestrear por separado los errores de A y B. Reportar el intervalo percentil del 95 % como análisis de sensibilidad aproximado. Dos ejecuciones con la misma semilla deben dar el mismo intervalo.

```
SEED = 20260829
BOOTSTRAP_RESAMPLES = 10_000
```

Tarea 7 - Ejecutar el pipeline y redactar la conclusión

El programa debe guardar `output/store_differences.csv` (la tabla pareada) y `output/store_differences.png`, y mostrar el resumen, la prueba t, la referencia por cambios de signo y el intervalo bootstrap. Completar las preguntas 11 a 17 y redactar el informe ejecutivo

de máximo 150 palabras de la pregunta 18. La conclusión debe incluir unidad, procedencia, métrica, emparejamiento, efecto, incertidumbre, procedimiento, p-value, sensibilidad, al menos dos limitaciones y una frase explícita sobre lo que no puede concluirse.

Entregable

- El código fuente en Python que produce todos los resultados.
- `output/store_differences.csv` y `output/store_differences.png`.
- `informe.md` con las cinco partes y las 18 preguntas del Anexo, en el mismo orden y numeración. La respuesta 18 no supera las 150 palabras.
- Toda cifra del informe debe provenir de una ejecución del código.

Anexo - Preguntas de informe.md

Complete las respuestas con frases propias y cite los resultados numéricos obtenidos por su programa. Una salida de software sin interpretación no constituye una respuesta.

Parte 1. Contrato de análisis previo (responder antes de ejecutar la comparación estadística)

1. ¿Qué dos modelos se comparan?
2. ¿Qué población o proceso objetivo propone para interpretar el ejercicio? Aclare qué impide afirmar que los datos sintéticos representan realmente esa población.
3. ¿Cuál es la métrica principal y qué dirección representa un mejor resultado?
4. ¿Cuál es la unidad de análisis?
5. ¿Por qué las observaciones están emparejadas y cómo verificará los pares?
6. Defina el estimando y la diferencia por tienda. Explique qué significa una diferencia positiva.
7. Escriba la hipótesis nula y la alternativa bilateral.
8. ¿Cuál será el procedimiento principal y qué supuestos requiere?
9. ¿Qué resultados reportará además del p-value?
10. ¿Qué afirmaciones no permite realizar este diseño?

Parte 2. Auditoría y evidencia por tienda

11. Confirme que los 16 pares fueron validados mediante `store_id`. Explique por qué comprobar únicamente que ambas columnas tienen la misma longitud no es suficiente.
12. Indique cuántas tiendas favorecen a A, cuántas favorecen a B y si existen empates. Identifique las diferencias de mayor magnitud en cada dirección.

Parte 3. Efecto e incertidumbre

13. Reporte el número de tiendas, la diferencia media, la desviación estándar muestral y el error estándar. Interprete el signo y la magnitud de la diferencia media en unidades vendidas.
14. Reporte el intervalo t del 95 %. Explique qué valores del efecto son compatibles con los datos bajo el modelo utilizado. No interprete el intervalo como una probabilidad posterior sobre el parámetro.

Parte 4. Referencias nulas y sensibilidad

15. Reporte el estadístico t, sus grados de libertad y el p-value bilateral. Explique correctamente qué representa ese p-value.
16. Reporte el p-value de la prueba exacta por cambios de signo. Explique por qué esta referencia nula y la prueba t no tienen supuestos idénticos.
17. Reporte el intervalo bootstrap pareado, la semilla y el número de remuestras. Explique por qué se remuestran tiendas completas y qué problema no puede corregir automáticamente el bootstrap.

Parte 5. Informe ejecutivo

18. Redacte un máximo de 150 palabras que incluya unidad, procedencia, métrica, emparejamiento, efecto, incertidumbre, procedimiento, p-value, análisis de sensibilidad, al menos dos limitaciones y una afirmación explícita sobre lo que no puede concluirse.